

# Desafio 2: treinar 48 camadas sem normalização

Douglas Ferreira Martins e Gullit Damião Teixeira de Campos • GBC073 Inteligência Computacional, UFU

## A solução

**Ativação:**  $f(x) = \tanh(x)$  — suave e simétrica

**Escala:**  $s^2$  calibrado numericamente via amostragem de  $E[f(z)^2]$

**Pesos:** ganho aplicado a uma matriz ORTOGONAL, não i.i.d. Gaussiana


## Por quê

Calibrar a variância garante só o sinal indo pra frente. Pesos ortogonais preservam a norma do vetor EXATAMENTE (não em média) — eliminando a dispersão que pesos aleatórios acumulam a cada camada. Combinada com tanh, essa é a receita de isometria dinâmica (Pennington, Schoenholz & Ganguli, 2017/2018): sinal e gradiente preservados em qualquer profundidade, sem BatchNorm nem conexões residuais.

**$S \approx 55,2$**

Em  $L = 48$ , supera a referência do professor (ReLU + He) — que nem sempre consegue treinar nessa profundidade.

## Variância da pré-ativação por camada (passo 0)



Linha central ( $\log_{10} = 0$ ) = variância  $\approx 1$ : sinal preservado. Baseline e pesos i.i.d. calibrados se afastam dela exponencialmente com a profundidade; pesos ortogonais mantêm a rede perto dela em qualquer  $L$ .