Sinais do treino alinhados no eixo de passos

Melhor
muon η=0.1 (adamw 0.001)
warmup_cosseno
F1 macro val = 0.567

Baseline
sgd η=0.001
constante
F1 macro val = 0.455

Melhor com Muon
muon η=0.1 (adamw 0.001)
warmup_cosseno
F1 macro val = 0.567

Instável
sgd η=10
constante
F1 macro val = nan [DIVERGIU]

perda (lote)

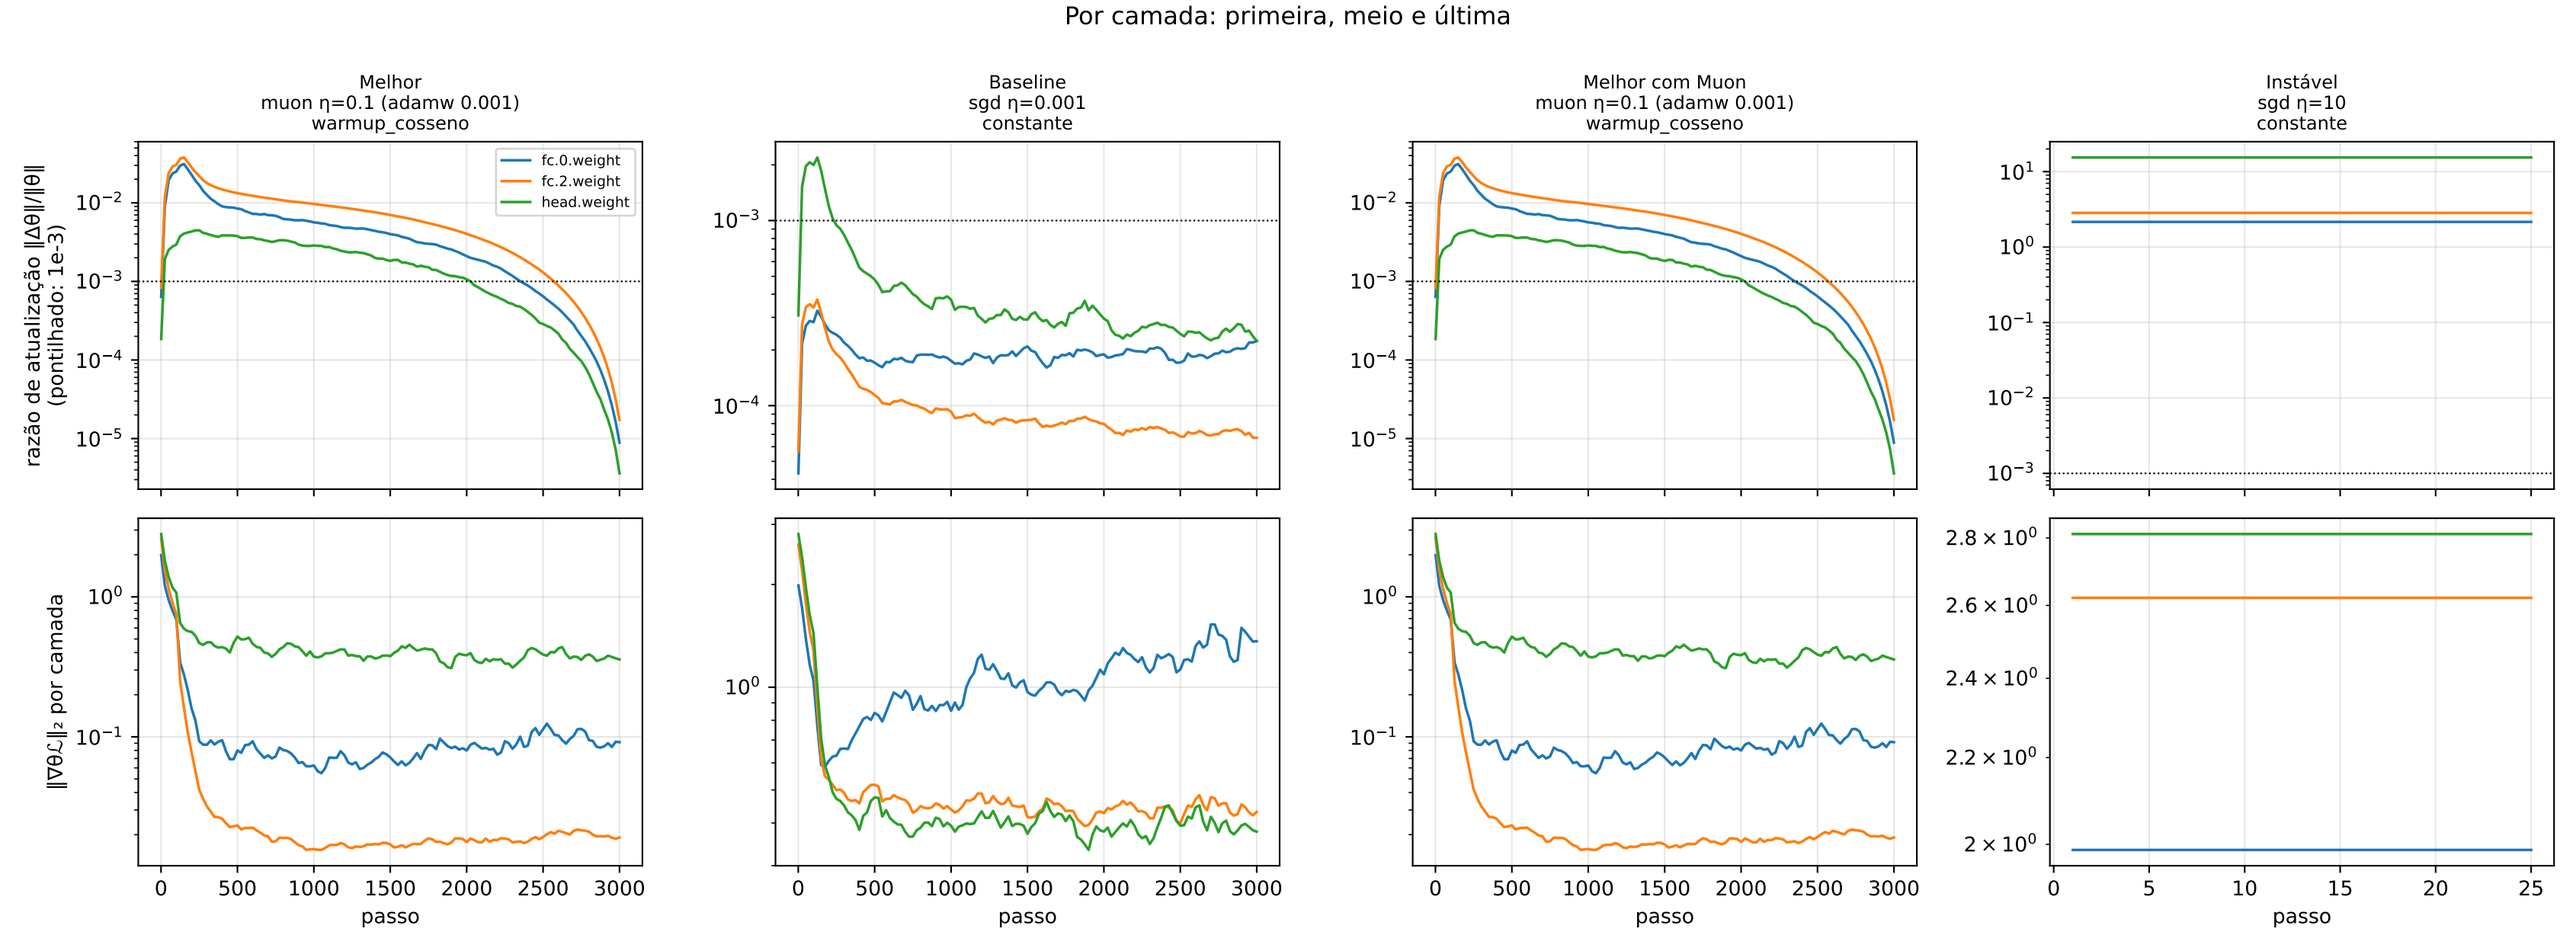
validação

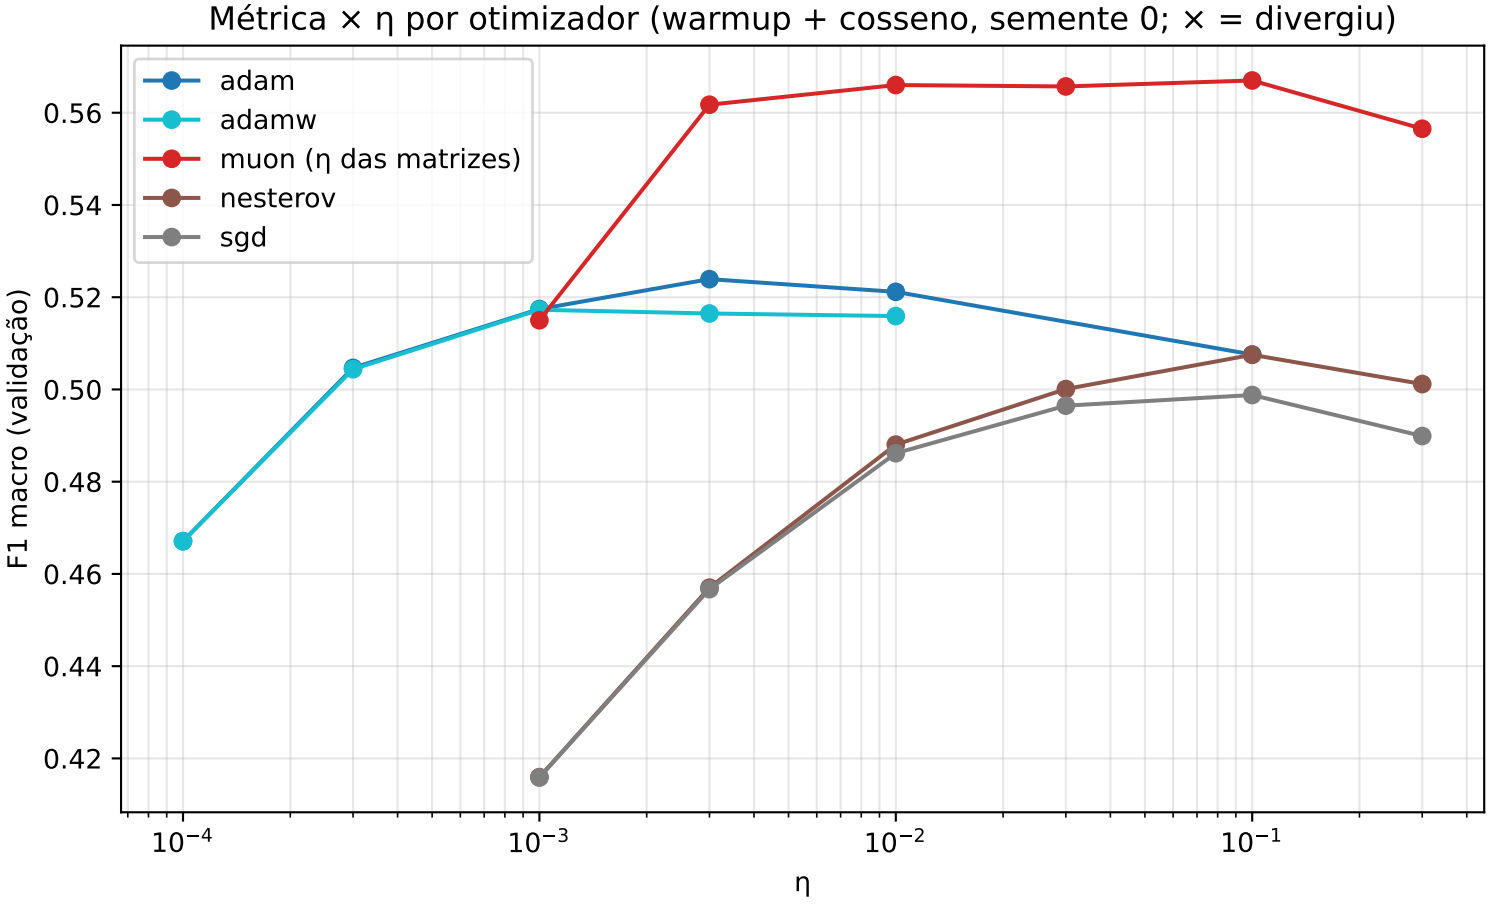
$\|\nabla_\theta \mathcal{L}\|_2$ (antes do clip)

$\|\theta\|_2$

η_t

passo


Por camada: primeira, meio e última
Melhor
muon η=0.1 (adamw 0.001)
warmup_cosseno
Baseline
sgd η=0.001
constante
Melhor com Muon
muon η=0.1 (adamw 0.001)
warmup_cosseno
Instável
sgd η=10
constante
razão de atualização ‖Δθ‖/‖θ‖
(pontilhado: 1e-3)
fc.0.weight
fc.2.weight
head.weight
‖∇θℒ‖₂ por camada
passo
passo
passo
passo


Métrica × η por otimizador (warmup + cosseno, semente 0; × = divergiu)
adam
adamw
muon (η das matrizes)
nesterov
sgd
F1 macro (validação)
0.56
0.54
0.52
0.50
0.48
0.46
0.44
0.42
10^{-4}
10^{-3}
10^{-2}
10^{-1}
η