Muon: +0,08 de F1 macro no teste e variação 5× menor que a do Adam

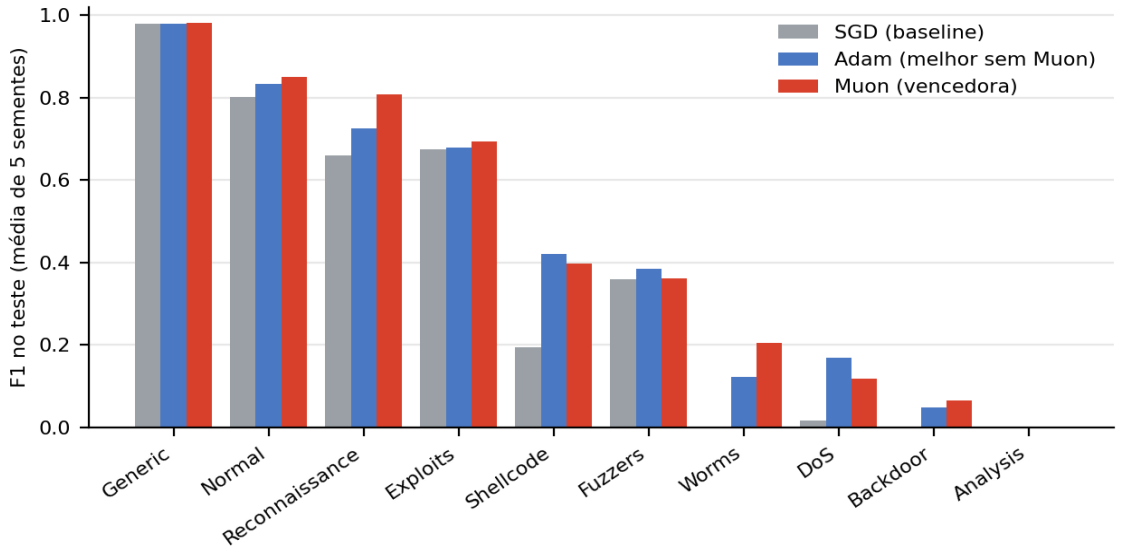
UNSW-NB15 (10 classes de attack_cat) · MLP 3×256 · softmax + entropia cruzada · 3000 passos, lote 256 · lr ajustado por otimizador · 5 sementes · teste usado uma vez

Receita vencedora

• **Muon** nas matrizes ocultas (lr 0,1, Newton–Schulz de 5 passos) + **AdamW** no resto (lr 1e-3, wd 0,01)
• Agenda **warmup 5% + cosseno** até 0 · clipping 1,0

Configuração	Val. F1 macro	Teste F1 macro
SGD lr 1e-3, constante (baseline)	0,446 ± 0,006	0,369 ± 0,005
Adam lr 3e-3, constante (melhor sem Muon)	0,520 ± 0,037	0,436 ± 0,030
Muon lr 0,1, warmup+cosseno	**0,566 ± 0,002**	**0,448 ± 0,006**

Ganho do Muon (média de 5 sementes): sobre a baseline **+0,12** (val.) e **+0,08** (teste), acima do desvio. Sobre o Adam ajustado: +0,05 (val.) e +0,01 (teste), este dentro da variação do Adam; o ganho robusto é a estabilidade.



Diagnóstico lido nos sinais de treino (painel.pdf)

Baseline: passo pequeno demais.

Razão de atualização (passo relativo por camada) de 7e-5 a 3e-4, abaixo da referência de 1e-3 em quase todo o treino; a norma dos parâmetros praticamente não sai de 32,1 e a perda ainda cai no passo 3000. A varredura confirma: o SGD só chega ao seu melhor com lr 0,1.

Muon: passo grande, que assenta no fim.

Razão de atualização entre 1e-3 e 1e-2 nas três camadas monitoradas até ~2000 passos (cerca de 10× a do SGD), sem picos na norma do gradiente e com perda de treino ~ validação (sem sobreajuste). O cosseno leva a razão a 1e-5 no fim: a queda final assenta no vale.

Efeito nas classes raras (teste).

F1 no teste, Muon vs Adam vs SGD: Worms 0,20 / 0,12 / 0,00, Backdoor 0,07 / 0,05 / 0,00, Reconnaissance 0,81 / 0,73 / 0,66. Analysis fica em 0 para todos e o DoS é pior que no Adam.

Nota: o F1 macro no teste (~0,45) é bem menor que na validação (~0,57): a partição oficial de teste tem outra distribuição de classes. Todas as execuções (inclusive exploratórias) estão em experimentos.csv e logs/.