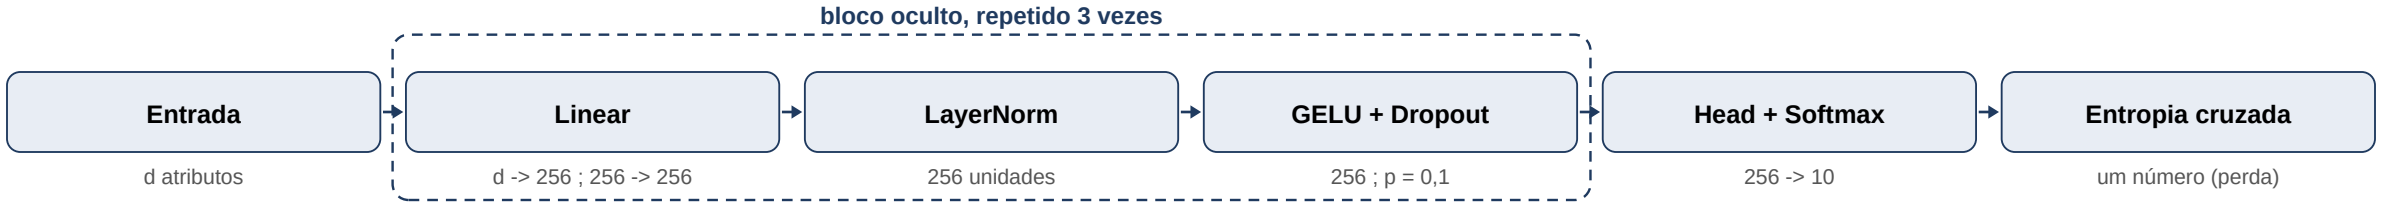
O modelo: MLP com LayerNorm e classificação por softmax

Cada fluxo de rede recebe uma de 10 classes (attack_cat): Normal, Generic, Exploits, Fuzzers, DoS, Reconnaissance, Analysis, Backdoor, Shellcode, Worms



Entrada

42 atributos do fluxo: 39 numéricos (log1p nos de cauda pesada, depois padronização com média e desvio do treino) e 3 categóricos (proto, service, state) em one-hot. Resulta em um vetor de d números.

Linear

y = W·x + b. Cada unidade combina todos os números da camada anterior com pesos aprendidos. São 3 camadas ocultas de 256 unidades (d -> 256, depois 256 -> 256 duas vezes). W é a matriz que o Muon atualiza.

LayerNorm

Normaliza as 256 ativações de cada amostra (média 0, variância 1) e aplica ganho e viés aprendidos. Mantém a escala estável entre camadas, o que ajuda o treino, e não depende do tamanho do lote.

GELU e Dropout

GELU: não linearidade suave, que permite fronteiras não lineares entre as classes. Dropout (p = 0,1): zera 10% das ativações ao acaso, só no treino, como regularização.

Head e softmax

Head: Linear 256 -> 10, um número (logit z) por classe. Softmax: p_k = exp(z_k) / soma_j exp(z_j), 10 probabilidades que somam 1. Previsão = classe de maior p.

Entropia cruzada

L = -log p_y, com y a classe verdadeira, em média sobre o lote. É pequena quando o modelo dá alta probabilidade à classe certa. Sem pesos por classe: as raras pesam pouco.

Lote	Passos	Épocas	Treino	Validação	Teste	Clip do gradiente	Parâmetros
256	**3000**	**~5,5**	**~140 mil**	**~35 mil (20%)**	**82.332**	**1,0**	**~190 mil**

Treino: cada época sorteia os exemplos sem repetição; 547 passos por época; 3000 passos × 256 amostras = 768 mil amostras vistas. Métrica de seleção: F1 macro (média simples dos F1 das 10 classes) na validação.

Comparação: SGD com momento 0,9 (com e sem Nesterov), Adam, AdamW e Muon + AdamW · agendas constante, cosseno, warmup + cosseno e WSD · lr ajustado por otimizador em grade logarítmica · mesmo orçamento para todos.

Muon: +0,08 de F1 macro no teste e variação 5× menor que a do Adam

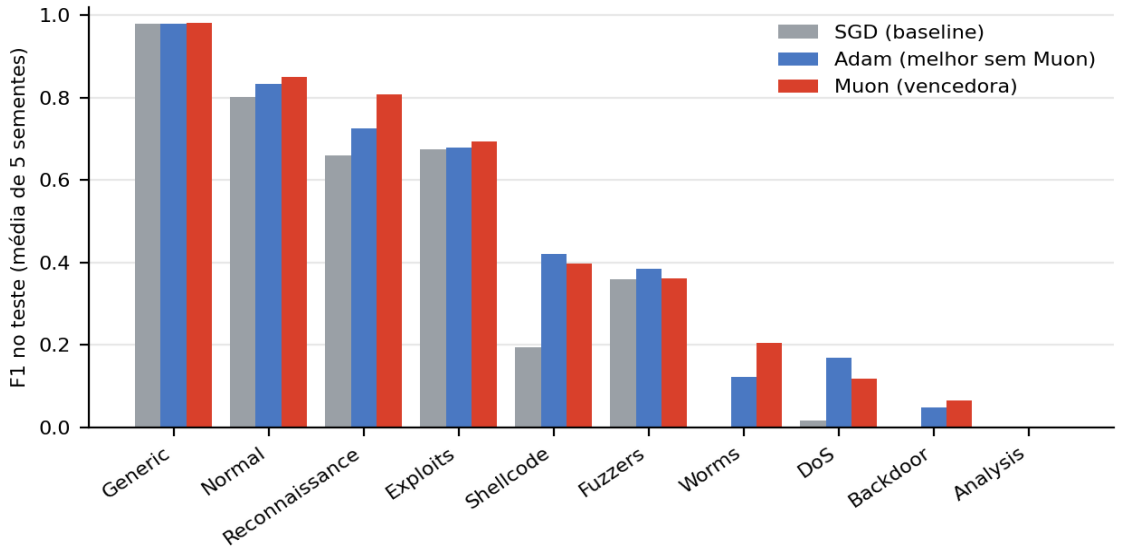
UNSW-NB15 (10 classes de attack_cat) · MLP 3×256 · softmax + entropia cruzada · 3000 passos, lote 256 · lr ajustado por otimizador · 5 sementes · teste usado uma vez

Receita vencedora

• **Muon** nas matrizes ocultas (lr 0,1, Newton–Schulz de 5 passos) + **AdamW** no resto (lr 1e-3, wd 0,01)
• Agenda **warmup 5% + cosseno** até 0 · clipping 1,0

Configuração	Val. F1 macro	Teste F1 macro
SGD lr 1e-3, constante (baseline)	0,446 ± 0,006	0,369 ± 0,005
Adam lr 3e-3, constante (melhor sem Muon)	0,520 ± 0,037	0,436 ± 0,030
Muon lr 0,1, warmup+cosseno	**0,566 ± 0,002**	**0,448 ± 0,006**

Ganho do Muon (média de 5 sementes): sobre a baseline **+0,12** (val.) e **+0,08** (teste), acima do desvio. Sobre o Adam ajustado: +0,05 (val.) e +0,01 (teste), este dentro da variação do Adam; o ganho robusto é a estabilidade.



Diagnóstico lido nos sinais de treino (painel.pdf)

Baseline: passo pequeno demais.

Razão de atualização (passo relativo por camada) de 7e-5 a 3e-4, abaixo da referência de 1e-3 em quase todo o treino; a norma dos parâmetros praticamente não sai de 32,1 e a perda ainda cai no passo 3000. A varredura confirma: o SGD só chega ao seu melhor com lr 0,1.

Muon: passo grande, que assenta no fim.

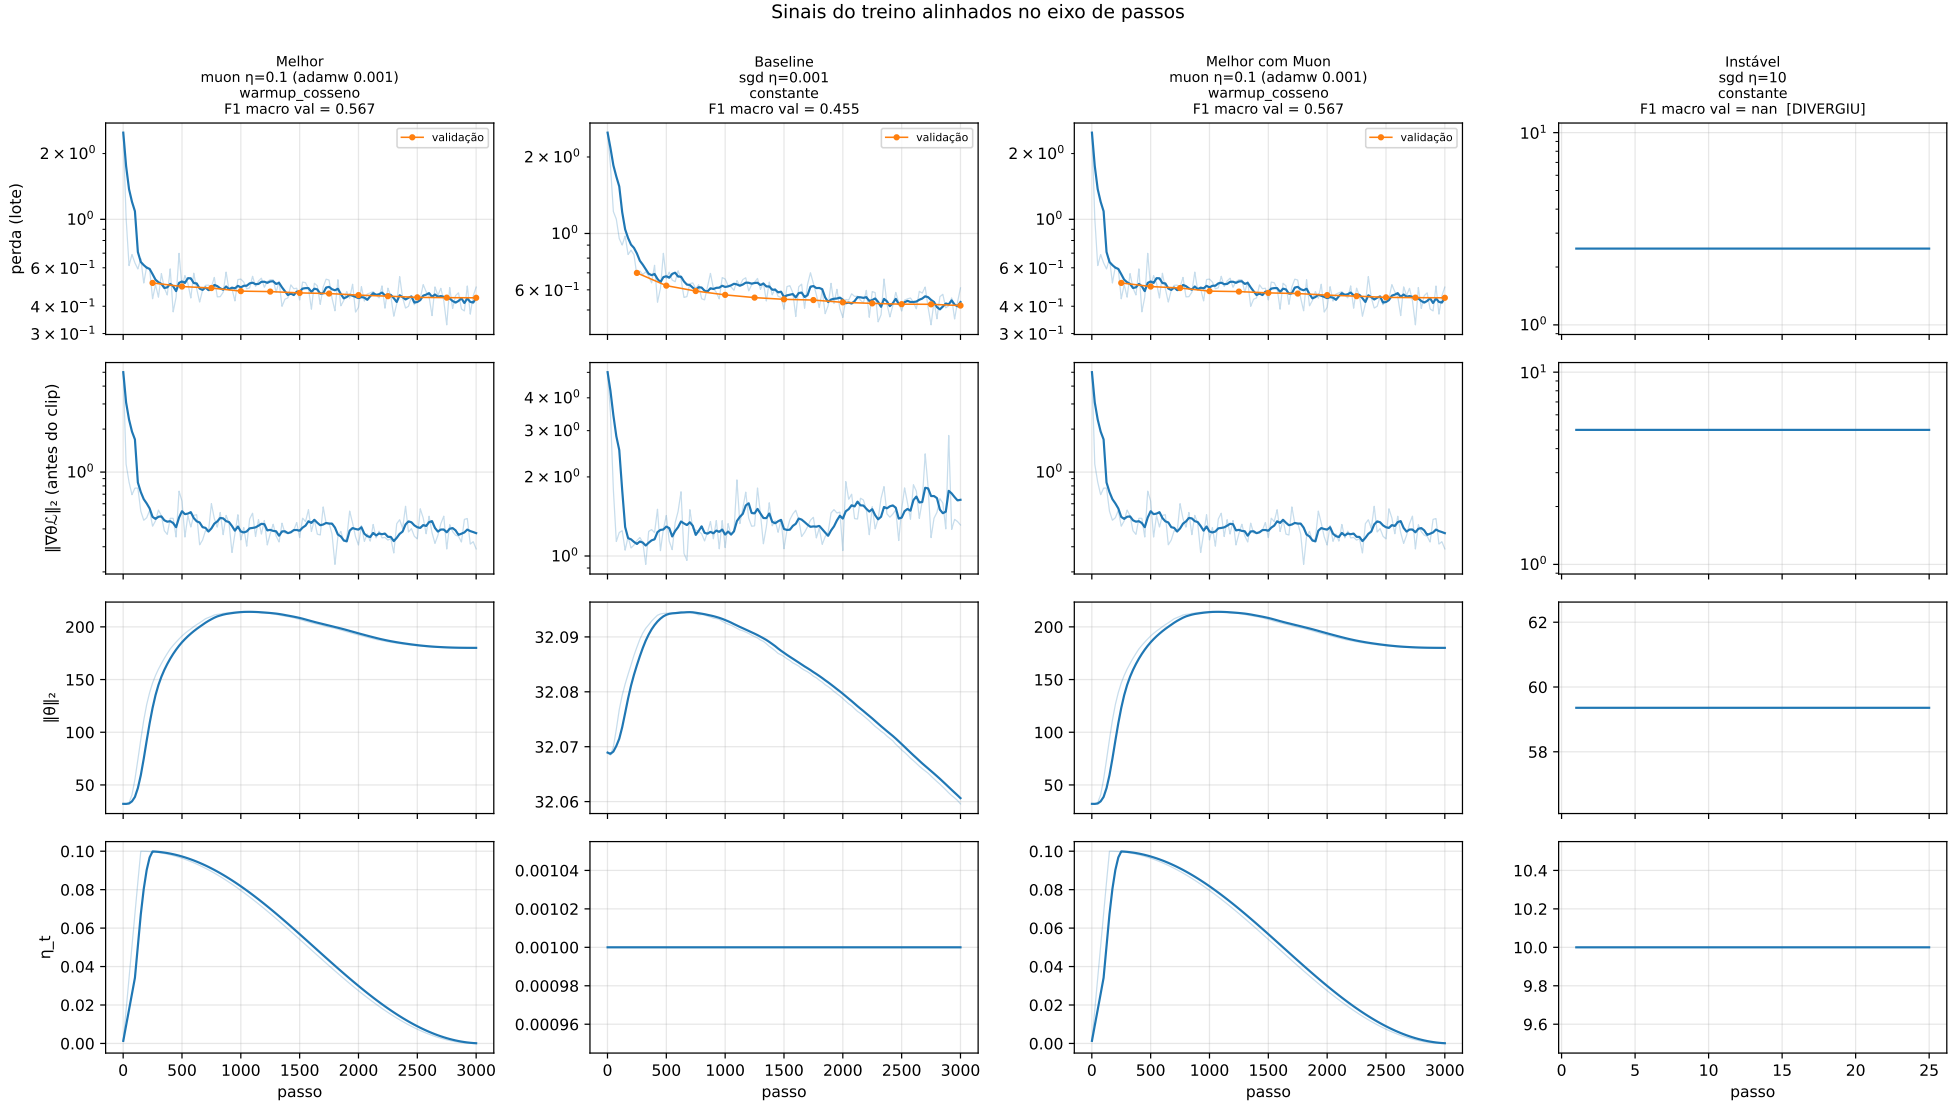
Razão de atualização entre 1e-3 e 1e-2 nas três camadas monitoradas até ~2000 passos (cerca de 10× a do SGD), sem picos na norma do gradiente e com perda de treino ~ validação (sem sobreajuste). O cosseno leva a razão a 1e-5 no fim: a queda final assenta no vale.

Efeito nas classes raras (teste).

F1 no teste, Muon vs Adam vs SGD: Worms 0,20 / 0,12 / 0,00, Backdoor 0,07 / 0,05 / 0,00, Reconnaissance 0,81 / 0,73 / 0,66. Analysis fica em 0 para todos e o DoS é pior que no Adam.

Nota: o F1 macro no teste (~0,45) é bem menor que na validação (~0,57): a partição oficial de teste tem outra distribuição de classes. Todas as execuções (inclusive exploratórias) estão em experimentos.csv e logs/.

Painel: os sinais do treino alinhados no eixo de passos



Instável (SGD, lr 10, constante): diverge entre os passos 1 e 25 (perda NaN). Só o passo 1 é finito, e as linhas planas são esse único ponto: a razão de atualização é de 2 a 15 por passo (a referência é 1e-3) e a norma dos parâmetros vai de 32 para 59 em um único passo: passo grande demais. Por camada e métrica × lr: painel.pdf, págs. 2 e 3.